UNIFEOB — CENTRO UNIVERSITÁRIO

ECOSSISTEMA HADOOP

Aplicação ao Projeto Burnout Data Science

Projeto: Monitoramento de Clima Organizacional e Prevenção Preditiva de Burnout Operacional
Grupo: 6
Integrantes: Calebe Matheus Moreira Moraes; Leandro Jose de Carvalho Coelho; Lucas Vigo Calio
Disciplina: Análise de Dados

São João da Boa Vista — SP

2026

1. Introdução

O projeto Monitoramento de Clima Organizacional e Prevenção Preditiva de Burnout Operacional tem como objetivo analisar dados relacionados à rotina dos colaboradores para identificar possíveis sinais de sobrecarga, exaustão profissional e risco de rotatividade. Entre os dados considerados estão horas extras, registros de ponto, atividades realizadas fora do expediente e respostas de pesquisas de clima organizacional.

O ecossistema Hadoop pode ser utilizado para armazenar e processar grandes volumes de dados de forma distribuída. Sua adoção seria uma possibilidade de evolução da arquitetura do projeto, que atualmente considera Python, Pandas, ETL, PostgreSQL, Docker e a organização dos dados nas camadas Bronze, Silver e Gold. A proposta descrita neste relatório é conceitual e não significa que o Hadoop já esteja instalado no ambiente.

2. Objetivo

Compreender como os principais componentes do Hadoop podem contribuir para armazenar, organizar, processar e consultar dados do Projeto Burnout. A arquitetura distribuída permitiria dividir tarefas entre diferentes máquinas, ampliar a capacidade de processamento e preparar informações para análises estatísticas e modelos preditivos.

3. Componentes principais do Hadoop

3.1 HDFS — Hadoop Distributed File System

O HDFS é um sistema de arquivos distribuído que armazena arquivos em blocos distribuídos entre máquinas de um cluster. Também pode manter réplicas dos blocos para aumentar a tolerância a falhas. No Projeto Burnout, poderia armazenar dados brutos de ponto, horas extras e pesquisas de clima na camada Bronze, além de dados tratados nas camadas Silver e Gold.

3.2 YARN — Yet Another Resource Negotiator

O YARN gerencia recursos computacionais do cluster, como memória e capacidade de processamento, e coordena a execução de aplicações. No projeto, poderia organizar recursos para tarefas como limpeza dos registros, cálculo de horas extras por departamento e geração de indicadores.

3.3 MapReduce

MapReduce é um modelo de processamento distribuído. A etapa Map transforma os registros em pares de chave e valor; a etapa Reduce agrupa os valores e consolida os resultados. Por exemplo, cada registro pode ser associado ao departamento e às horas extras, e depois os valores podem ser somados por departamento.

Exemplo didático de entrada para o processamento:

Departamento	Horas extras (exemplo)
TI	120
RH	45
Financeiro	80
TI	60

Após o agrupamento, o resultado seria TI = 180 horas, RH = 45 horas e Financeiro = 80 horas. Esses valores são apenas ilustrativos. O total de horas extras, isoladamente, não determina a existência de burnout; deve ser analisado junto a outros indicadores e com cuidado.

4. Ferramentas complementares

Ferramenta	Função	Aplicação no projeto
Apache Hive	Consultas em dados do Hadoop usando linguagem semelhante a SQL.	Consultar médias, totais e indicadores por departamento.
Apache Pig	Linguagem de fluxo de dados para transformação em larga escala.	Organizar filtros e transformações de ETL.
Apache Sqoop	Transferência em lote entre bancos relacionais e Hadoop; ferramenta tradicional.	Poderia integrar PostgreSQL e Hadoop, após verificar compatibilidade da versão.
Apache HBase	Banco NoSQL distribuído para tabelas muito grandes e acesso a registros específicos.	Consultar rapidamente indicadores ou eventos em uma implantação de maior escala.

Para o cenário acadêmico atual, HDFS, Hive e o entendimento de YARN e MapReduce são os componentes mais diretamente relacionados à proposta. Pig, Sqoop e HBase são alternativas que podem ser consideradas conforme as necessidades e a compatibilidade técnica. Não é necessário utilizar todas as ferramentas ao mesmo tempo.

5. Arquitetura proposta

A arquitetura abaixo representa um possível fluxo de dados, integrando as camadas já utilizadas no projeto com componentes Hadoop.

Etapa	Descrição
1. Fontes de dados	Registros de ponto, horas extras, atividades fora do expediente e pesquisas de clima.
2. HDFS — Bronze	Armazenamento dos arquivos brutos recebidos.
3. Processamento	YARN coordena recursos; MapReduce realiza cálculos distribuídos; Pig pode apoiar transformações.
4. HDFS — Silver e Gold	Armazenamento de dados limpos, padronizados e indicadores consolidados.
5. Análise e apresentação	Hive para consultas; Python/Pandas e modelos preditivos para análises; PostgreSQL para resultados estruturados, quando necessário.

O fluxo é uma proposta de arquitetura, não uma descrição de componentes já instalados. A integração real exigiria configurar o ambiente, testar formatos de arquivo e definir como os dados seriam transferidos entre os sistemas.

6. Exemplo prático de utilização

Considere uma empresa que acumule milhares de registros de ponto e horas extras ao longo de vários meses. Os arquivos seriam armazenados no HDFS; os dados passariam por verificações de valores ausentes, duplicidades e categorias inconsistentes; um processamento distribuído agruparia as horas extras por departamento; e consultas Hive permitiriam visualizar os totais e as médias. Python e Pandas poderiam combinar esses resultados com as pesquisas de clima para análises estatísticas e experimentos de modelos preditivos.

Os resultados serviriam como indicadores para investigar áreas que merecem acompanhamento, e não como diagnóstico automático de saúde. Uma aplicação real exigiria controles de acesso, minimização de dados e proteção das informações pessoais dos colaboradores.

7. Vantagens e limitações

Vantagens: armazenamento distribuído, processamento paralelo, possibilidade de expansão da infraestrutura e integração com ferramentas de consulta e análise.

Limitações: instalação e manutenção de cluster podem ser complexas; o Hadoop exige recursos computacionais e planejamento; para o conjunto de dados simulado e a infraestrutura atual, PostgreSQL e Pandas podem ser suficientes. A adoção deve ser justificada pelo volume e pelas necessidades do projeto.

8. Conclusão

O ecossistema Hadoop apresenta recursos para armazenar e processar grandes volumes de dados de forma distribuída. No Projeto Burnout, o HDFS poderia guardar os dados das camadas Bronze, Silver e Gold; o YARN gerenciaria os recursos; e o MapReduce permitiria realizar cálculos em paralelo. Hive, Pig, Sqoop e HBase poderiam complementar a arquitetura de acordo com as necessidades de consulta, transformação, integração e acesso aos dados.

Assim, o Hadoop representa uma possibilidade de evolução caso o volume de informações cresça. Sua integração com ETL, PostgreSQL e Python poderia ampliar a capacidade analítica e ajudar a identificar padrões de sobrecarga, sempre considerando que os indicadores devem ser interpretados em conjunto e não substituem avaliações profissionais.

9. Referências

APACHE SOFTWARE FOUNDATION. Apache Hadoop — Modules. Disponível em: https://hadoop.apache.org/modules.html. Acesso em: 21 out. 2026.

APACHE SOFTWARE FOUNDATION. Apache Hive. Disponível em: https://hive.apache.org/. Acesso em: 21 out. 2026.

APACHE SOFTWARE FOUNDATION. Apache HBase. Disponível em: https://hbase.apache.org/. Acesso em: 21 out. 2026.

APACHE SOFTWARE FOUNDATION. Apache Pig. Disponível em: https://pig.apache.org/. Acesso em: 21 out. 2026.

APACHE SOFTWARE FOUNDATION. Apache Sqoop. Disponível em: https://sqoop.apache.org/. Acesso em: 21 out. 2026.