PROJETO INTEGRADOR EM CIÊNCIA DE DADOS — ECOSSISTEMA BIG DATA

IMPLEMENTAÇÃO DO ECOSSISTEMA HADOOP PARA ANÁLISE DE BURNOUT ORGANIZACIONAL

Documentação Técnica, Arquitetura Medallion e Mapeamento de Componentes

Disciplina: Big Data & Analytics | Orientador: Prof. Gabriel | Grupo: 06

1. INTRODUÇÃO E OBJETIVOS

O presente relatório documenta o desenvolvimento e a execução da arquitetura de Big Data voltada ao monitoramento e à prevenção da Síndrome de Burnout no ambiente corporativo. A solução foi fundamentada no ecossistema Hadoop, capacitando a organização a processar volumes crescentes de dados operacionais e comportamentais de maneira distribuída, performática e resiliente a falhas.

O objetivo central consistiu em construir um pipeline capaz de ingerir dados brutos de registro de ponto e chamados de suporte, higienizá-los e sumarizar indicadores críticos por departamento (como média de horas extras, jornada total diária, atendimento fora de expediente e pontuação de clima organizacional).

2. ARQUITETURA DE ARMAZENAMENTO NO HDFS (ARQUITETURA MEDALLION)

O Hadoop Distributed File System (HDFS) atua como a camada mestra de armazenamento distribuído, garantindo tolerância a falhas via replicação de blocos. A organização lógica dos dados segue o padrão Medallion, garantindo governança e rastreabilidade da informação ao longo do ciclo de vida da ingestão:

Estrutura e Governança de Camadas no HDFS

Camada	Diretório HDFS Simulado	Volume	Descrição do Conteúdo e Tratamento
Bronze	`/hdfs_simulado/bronze`	1.020 reg.	Dados brutos extraídos do sistema (inconsistências, valores nulos e duplicatas intencionais).
Silver	`/hdfs_simulado/silver`	1.001 reg.	Base higienizada: remoção de 19 duplicatas, padronização de nomenclatura de setores e imputação de nulos.
Gold	`/hdfs_simulado/gold`	5 setores	Visões agregadas com médias operacionais por departamento prontas para BI e Machine Learning.

A separação entre as camadas Bronze e Silver assegura que os dados brutos permaneçam imutáveis para auditorias, enquanto a camada Gold disponibiliza exclusivamente dados consolidados e validados de alto valor analítico.

3. GESTÃO DE RECURSOS (YARN) E PROCESSAMENTO DISTRIBUÍDO (MAPREDUCE)

O gerenciamento dos recursos do cluster é conduzido pelo YARN (Yet Another Resource Negotiator), que aloca dinamicamente contêineres de CPU e memória RAM para os nós de processamento. Sob a gestão do YARN, o paradigma de programação MapReduce processa em lote o arquivo da camada Silver sem sobrecarregar a memória principal.

Fluxo de Execução Algorítmica do Job MapReduce

1. Etapa MAP: Lê os registros limpos da Silver e emite pares chave-valor contendo a chave `departamento` e os valores numéricos associados: `(horas_extras, horas_trabalhadas, tickets_fora_horario, nivel_clima)`.
2. Etapa SHUFFLE & SORT: O framework distribui e agrupa automaticamente todas as tuplas emitidas que compartilham a mesma chave de departamento.
3. Etapa REDUCE: Agregadores calculam a contagem de colaboradores e as médias aritméticas de cada métrica, gravando o resultado na camada Gold.

4. RESULTADOS OBTIDOS NO PROCESSAMENTO DISTRIBUÍDO

A execução bem-sucedida do job MapReduce sobre a base Silver gerou a consolidação analítica reproduzida na Tabela 1. Os dados revelam padrões críticos de sobrecarga laboral em setores estratégicos da empresa.

Tabela 1 — Indicadores operacionais e de clima por departamento (Camada Gold)

Departamento	Qtd. Colaboradores	Média Horas Extras	Jornada Média	Tickets Fora Horário	Clima (0-10)
Comercial	115	11,65 h	8,54 h	2,90	5,23
Financeiro	121	11,95 h	8,34 h	2,57	5,59
Operações	212	12,32 h CRÍTICO	8,69 h	2,91	5,33
Recursos Humanos	220	11,63 h	8,56 h	3,03 ALTO	5,35
Tecnologia da Informação	333	12,02 h ALTO	8,49 h	3,01 ALTO	5,60

Os resultados evidenciam que o setor de **Tecnologia da Informação** concentra o maior contingente absoluto (333 colaboradores) associado a uma alta demanda extramuro (3,01 tickets fora do expediente), enquanto o setor de **Operações** apresenta o maior volume médio de horas extras acumuladas (12,32 h/mês).

5. MAPEAMENTO E INTEGRAÇÃO DAS FERRAMENTAS DO ECOSSISTEMA HADOOP

Para prover uma arquitetura analítica completa, foram mapeadas e implementadas queries e rotinas declarativas para as ferramentas do ecossistema Hadoop complementares ao MapReduce nativo.

A. Consulta Ad-hoc com Apache Hive (HiveQL)

O Apache Hive provê uma camada de Data Warehouse que traduz consultas SQL em jobs MapReduce/Tez. A tabela externa mapeia diretamente os dados armazenados no HDFS Silver:

```
-- Criação de tabela externa Hive apontando para a camada Silver do HDFS CREATE EXTERNAL TABLE IF NOT EXISTS burnout_silver ( id_colaborador INT, nome STRING, departamento STRING, horas_extras DOUBLE, horas_trabalhadas DOUBLE, tickets_fora_horario INT, horario_ticket STRING, nivel_clima DOUBLE ) ROW FORMAT DELIMITED FIELDS TERMINATED BY ',' STORED AS TEXTFILE LOCATION '/hdfs_simulado/silver' TBLPROPERTIES ("skip.header.line.count"="1"); -- Consulta de identificação de departamentos com risco de burnout SELECT departamento, COUNT(id_colaborador) AS total, ROUND(AVG(horas_extras), 2) AS avg_extras, ROUND(AVG(tickets_fora_horario), 2) AS avg_tickets FROM burnout_silver GROUP BY departamento ORDER BY avg_extras DESC;
```

B. Pipeline ETL Declarativo com Apache Pig (Pig Latin)

O Apache Pig simplifica transformações complexas de fluxo de dados. O script abaixo ilustra a extração da camada Bronze, desduplicação e gravação na Gold:

```
dados_brutos = LOAD '/hdfs_simulado/bronze/dados_burnout.csv' USING PigStorage(',') AS (id:int, nome:chararray, dept:chararray, extras:double, hor:double, tkt:int, h_tkt:chararray, clima:double); dados_unicos = DISTINCT dados_brutos; grupo_dept = GROUP dados_unicos BY dept; indicadores = FOREACH grupo_dept GENERATE group AS dept, COUNT(dados_unicos) AS total, AVG(dados_unicos.extras) AS avg_extras, AVG(dados_unicos.clima) AS avg_clima; STORE indicadores INTO '/hdfs_simulado/gold/pig_resumo' USING PigStorage(',');
```

C. Ingestão e Exportação Relacional com Apache Sqoop

O Sqoop executa a transferência em massa entre bancos relacionais (PostgreSQL/MySQL) e o HDFS. Permite importar a tabela transacional de registro de ponto para a Bronze e exportar os KPIs finalizados da Gold para os dashboards executivos.

D. Armazenamento NoSQL de Baixa Latência com Apache HBase

O Apache HBase fornece acesso aleatório de leitura/escrita em tempo real sobre o HDFS. Na solução, o HBase é empregado para registrar o histórico individual do colaborador, viabilizando alertas imediatos para a equipe de Medicina e Segurança do Trabalho:

```
      # Criação da tabela de alertas pontuais create 'alertas_burnout', 'dados_pessoais',
'metricas' # Registro de colaborador com sobrecarga aguda identificada put 'alertas_burnout',
'1526', 'dados_pessoais:nome', 'Bernardo Vasconcelos' put 'alertas_burnout', '1526',
'dados_pessoais:departamento', 'Tecnologia da Informação' put 'alertas_burnout', '1526',
'metricas:horas_extras', '19.4' put 'alertas_burnout', '1526',
'metricas:tickets_fora_horario', '3'
```

6. ANÁLISE DE RISCO ORGANIZACIONAL E RECOMENDAÇÕES

Diretrizes de Intervenção Preventiva para a Gestão de Pessoas

1. **Redesenho de Escalas em TI e Operações:** Diante das médias de horas extras superiores a 12h mensais, recomenda-se a redistribuição de chamados e contratação de suporte em regimes de plantão rotativo.
2. **Bloqueio Institucional de Chamados Noturnos:** Estabelecer políticas de restrição de chamados fora do horário comercial, atacando a média de ~3 tickets/mês por colaborador identificada nos setores mais críticos.
3. **Monitoramento em Tempo Real via HBase:** Acionar protocolos de apoio psicológico e medicina laboral sempre que um colaborador ultrapassar o limiar de 15h extras mensais.

7. CONCLUSÃO

O ecossistema Hadoop demonstrou total aderência para equacionar o desafio do volume e da variedade de dados no Projeto Burnout. A combinação do HDFS para armazenamento estruturado em camadas, YARN para governança de recursos, MapReduce/Pig para ETL, Hive para consultas analíticas e HBase para respostas em tempo real consolida uma infraestrutura robusta, escalável e pronta para subsidiar a tomada de decisão em gestão de pessoas.

IDENTIFICAÇÃO ACADÊMICA DO PROJETO
Projeto Integrador: Ciência de Dados — Atividade Hadoop & Big Data
Integrantes: Grupo 06 | **Status da Implementação:** Concluído e Validado (1.001 registros processados)
Ambiente de Execução: Google Colab (Simulação HDFS/MapReduce/YARN) e Repositório GitHub